



CS221.Q13

PHÂN LOẠI MỨC ĐỘ ĐỘC HAI TRÊN VĂN BẢN MẠNG XÃ HỘI TIẾNG VIỆT

GVHD: TS. Nguyễn Trọng Chính


23521441 - Lê Đức Thành

23521555 - Huỳnh Diên Thục

23521245 - Nguyễn Ngọc Thanh Phương



Mục Lục





Giới thiệu bài toán

Vấn đề bài toán giải quyết

- Các bình luận mang tính xúc phạm, công kích và thù ghét xuất hiện với tần suất cao, gây ảnh hưởng tiêu cực đến môi trường mạng xã hội.
- Việc kiểm duyệt thủ công không khả thi khi dữ liệu lớn và cập nhật liên tục.

Bài toán tự động phân loại mức độ độc hại của văn bản mạng xã hội tiếng Việt, nhằm hỗ trợ phát hiện và xử lý nội dung độc hại nhanh chóng và hiệu quả.





Giới thiệu bài toán

Bài toán

Bài toán được mô hình hóa dưới dạng phân loại văn bản có giám sát, với ba mức độ:

- CLEAN – không độc hại.
- OFFENSIVE – xúc phạm.
- HATE – thù ghét, công kích có mục tiêu.

Thách Thức Của Bài Toán

- Ngôn ngữ mạng xã hội phi chuẩn: slang, viết tắt,...
- Khó phân biệt giữa OFFENSIVE và HATE: phụ thuộc ngữ cảnh.
- Hate speech hàm ý: không xúc phạm rõ ràng nhưng vẫn mang tính công kích.
- Mất cân bằng dữ liệu: các lớp độc hại xuất hiện ít hơn, gây khó khăn cho việc huấn luyện và đánh giá mô hình.



Phát biểu bài toán

Input:

1. Tập dữ liệu huấn luyện gồm N phần tử:

$$D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

- Tập các nhãn phân loại (Labels) của D :

$$L = \{0, 1, 2\}$$

(Quy ước: 0: Clean, 1: Offensive, 2: Hate)

- Trong mỗi phần tử của D :
 - $\mathbf{x}_i$ là vector đặc trưng (feature vector) biểu diễn nội dung bình luận, có kích thước n chiều:

$$\mathbf{x}_i \in R^n$$

- y_i là nhãn (label) thực tế được gán cho $\mathbf{x}_i$, với $y_i \in L$.

2. Nội dung bình luận mới cần phân loại:

$$\mathbf{x} \in R^n$$

Output:

- $\hat{y} \in L$: giá trị nhãn được dự đoán cho bình luận $\mathbf{x}$



Bộ Ngữ Liệu Sử Dụng

Bộ ngữ liệu UIT-ViHSD: gồm 33.400 mẫu bình luận được gán nhãn trong đó:


- **CLEAN:** 27.624 mẫu
- **HATE:** 3.514 mẫu
- **OFFENSIVE:** 2.262 mẫu



Bộ Ngữ Liệu Sử Dụng

Bộ ngữ liệu UIT-ViHSD: gồm 33.400 mẫu bình luận được gán nhãn trong đó:

- **CLEAN:** 27.624 mẫu
- **HATE:** 3.514 mẫu
- **OFFENSIVE:** 2.262 mẫu
- Ba tập train/dev/test hầu như không có giá trị thiếu hay bình luận rỗng (tỉ lệ `is_text_null` , `is_text_empty`).
- Có 5.458 dòng trùng nội dung ($\approx 16\%$ số dòng), trong đó 5.010 dòng trùng cả nội dung và nhãn, và 240 trường hợp cùng một nội dung nhưng được gán nhiều nhãn khác nhau.





Bộ Ngữ Liệu Sử Dụng

Cấu trúc nhãn của **bộ ngữ liệu UIT-ViHSD**:

- **CLEAN:**

- Không chứa nội dung quấy rối hay xúc phạm.
- Không có từ tục, không tấn công cá nhân hoặc nhóm người.
- Xem như nội dung “bình thường/chấp nhận được”.
- **Ví dụ 1:** "M.n ơi cho mik hỏi mik theo dõi cô mà mik hk pít cô là con gái thiệt hả m.n".
 - Giải thích: Câu này có nghĩa là "Mọi người ơi cho mình hỏi...". Mặc dù viết tắt (teencode: "mik", "hk pít"), nhưng nội dung hoàn toàn sạch, chỉ là một câu hỏi thắc mắc bình thường và không tấn công ai.
- **Ví dụ 2:** "Nhanh thực sự".
 - Giải thích: Một lời nhận xét bình thường, không mang ý nghĩa tiêu cực.



Bộ Ngữ Liệu Sử Dụng

Cấu trúc nhãn của **bộ ngữ liệu UIT-ViHSD**:

- **OFFENSIVE:**

- Có nội dung xúc phạm, quấy rối, có thể dùng từ tục, từ lóng.
- Không nhắm rõ ràng vào một cá nhân hoặc một nhóm người dựa trên đặc trưng xã hội (dân tộc, tôn giáo, quốc tịch, vùng miền,...).
- Ngôn ngữ “thô tục/toxic” nhưng chưa phải hate speech theo nghĩa phân biệt đối xử.
- **Ví dụ 1:** "Đồ khùng".
 - Giải thích: Chứa từ phản cảm "khùng". Tuy nhiên, trong ngữ cảnh này, nó không nhắm vào một người hay nhóm cụ thể nào, hoặc từ "khùng" chỉ được dùng như một từ lóng.
- **Ví dụ 2:** "Đm chứ biết làm gì".
 - Giải thích: Chứa từ chửi thề tục tĩu "Đm", nhưng câu này mang tính than vãn hoặc chửi đồng, không xác định mục tiêu bị tấn công.



Bộ Ngữ Liệu Sử Dụng

Cấu trúc nhân của **bộ ngữ liệu UIT-ViHSD**:

- **HATE:**

- Có nội dung xúc phạm/thù ghét.
- Nhắm trực tiếp vào cá nhân hoặc nhóm người dựa trên các đặc trưng như dân tộc, tôn giáo, quốc tịch, vùng miền, giới tính,...
- **Dạng 1:** Tấn công trực tiếp bằng từ ngữ tục tĩu (Explicit)
 - **Ví dụ:** "Nó học cách của thằng anh nó đó, hèn, khốn nạn"
- **Dạng 2:** Phân biệt chủng tộc/vùng miền ẩn ý (Implicit)
 - **Ví dụ:** "Ở đây ngọt ngọt quá thì đưa nó qua cho nó thoáng mát"
- **Dạng 3:** Dùng nghĩa bóng/ẩn dụ (Figurative)
 - **Ví dụ:** "Dành cho lũ quan ngại"





Khảo Sát Một Số Nhân Trong Ngữ Liệu

- Khảo sát một số nhân trong **bộ ngữ liệu UIT-ViHSD**:

STT	Label	Nội dung bình luận	Giải thích
1	CLEAN	Đậu Văn Cường giờ giống thằng sida hơn à	Nhân có thể sai vì "thằng sida" là từ xúc phạm nhân phẩm nặng nề, cần sửa thành HATE.
2	CLEAN	Tú thích hoa hồng và mùa đông được Quang đâm phía sau mông	Cụm “đâm phía sau mông” là ngôn ngữ ẩn dụ ám chỉ quan hệ tình dục, mang tính quấy rối tình dục nhắm vào cá nhân cụ thể (Tú, Quang). Do đó, nhân đúng phải là HATE (hoặc ít nhất OFFENSIVE)
3	OFFENSIVE	Dạy bơi cho cá. Bơi thì đương nhiên nó bơi được vì nó là cá. Làm sao cho nó sống được mới là điều người dân đang quan tâm.	Nhân có thể sai vì câu hoàn toàn không chứa từ tục tĩu (yếu tố bắt buộc của OFFENSIVE), thực chất là châm biếm xã hội.
4	HATE	Thật chán với chế độ quản lý dân sinh	Nhân có thể sai vì đây chỉ là quan điểm chính trị trái chiều (Negative Sentiment) chứ không chứa từ ngữ lăng mạ hay quấy rối.




Bộ Ngữ Liệu Sử Dụng





Bộ Ngữ Liệu Sử Dụng



Hiện tại, nhóm sử dụng danh sách stop-word của ngôn ngữ Việt Nam từ [List Vietnamse Stopwords](#)



Bộ Ngữ Liệu Sử Dụng


Đặc trưng của bộ ngữ liệu **UIT-ViHSD**:

- **Các từ phổ biến:**

- “mẹ”,
- “vl”,
- “đéo”,
- “bố”,
- ...



Nội Dung Thực Hiện





Tiền Xử Lý Ngữ Liệu

- **Word Segmentation** (Tách từ)
 - Ví dụ: sinh viên → sinh_viên; đất nước → đất_nước.
- **Stopword Removal - Safe Mode**
 - Ví dụ: “bài hát này thì quá hay” → “bài_hát quá hay” (Loại bỏ từ "thì", "này").
- **Xử lý ký tự đặc biệt (Regex)**
 - Ví dụ: “Xem tại http://abc.com #covid” → “xem tại covid”.
- **Chuẩn hóa chữ thường (Lowercase Normalization)**
 - Ví dụ: “Việt Nam”, “VIỆT NAM”, “việt Nam” → đồng nhất thành “việt_nam”.



Feature extraction

Tại sao dùng TF-IDF?

- Biểu diễn văn bản dưới dạng vector trọng số (dạng số) để mô hình ML xử lý được.
- Nhấn mạnh các từ/ngữ n-gram mang tính phân biệt giữa các lớp.
- Giảm tác động của các từ quá phổ biến (ít giá trị phân loại).
- Giúp các mô hình truyền thống (Naive Bayes, Logistic Regression, SVM, ...) học hiệu quả.
- Phù hợp với dữ liệu văn bản thưa (sparse) và từ vựng lớn.



Multinomial Naive Bayes

Ưu điểm

- Tốc độ & Tài nguyên: Huấn luyện nhanh, dự đoán tức thì (Real-time), chạy mượt trên CPU.
- Hiệu quả với dữ liệu văn bản: Xử lý tốt vector thưa (Sparse Vectors) từ bộ từ vựng lớn của UIT-ViHSD (bao gồm cả Teencode, từ viết tắt).
- Dễ giải thích (Interpretability): Dễ dàng chỉ ra các từ khóa cụ thể (bad words) đóng góp vào xác suất phân loại.

Phù hợp với bài toán

- Dữ liệu là các văn bản (TF-IDF)
- Bài toán có nhiều lớp (multi-class classification)



Multinomial Naive Bayes

Quy trình huấn luyện


- Sử dụng tập Train để học.
- Sử dụng tập Dev để tinh chỉnh tham số (Hyperparameter Tuning) thông qua RandomizedSearchCV.
- Và chỉ đánh giá một lần duy nhất trên tập Test.

Tham số tối ưu sau khi training

- Alpha : 0.004582133690843357
- fit_prior: True
- tfidf__analyzer: "word",
- tfidf__max_df: 1.0,
- tfidf__max_features: 50000,
- tfidf__min_df: 1,
- tfidf__ngram_range: (1,2)



Multinomial Naive Bayes



Report:

	precision	recall	f1-score	support
0	0.8923	0.9524	0.9214	5548
1	0.4350	0.1734	0.2480	444
2	0.4957	0.4186	0.4539	688
accuracy			0.8457	6680
macro avg	0.6077	0.5148	0.5411	6680
weighted avg	0.8210	0.8457	0.8285	6680









Thực Nghiệm và Đánh Giá

	Accuracy	F1-score macro
Naive Bayes	84.56%	54.11%
Logistic Regression	86.33%	62.80%
PhoBert	86.78%	63.16%
SVM	86.11%	62.17%
KNN	83.61%	46.08%
Decision Tree	82.62%	51.66%



Phân tích một case cụ thể

GLOBAL WORD WEIGHTS (Top features per class by LOG-ODDS)





Phân tích một case cụ thể

INPUT: lũ ngu vô_học ... viết tiêu_đề sai chính_tả .

TOKENIZE:

Num tokens/ngrams: 13

In-vocab tokens : 8

Out-Of-Vocabulary tokens : 5

Tokens : ['lũ', 'ngu', 'vô_học', 'viết', 'tiêu_đề', 'sai', 'chính_tả', 'lũ ngu', 'ngu vô_học', 'vô_học viết', 'viết tiêu_đề', 'tiêu_đề sai', 'sai chính_tả']

Out-Of-Vocabulary tokens : ['tiêu_đề', 'ngu vô_học', 'vô_học viết', 'viết tiêu_đề', 'tiêu_đề sai']



Phân tích một case cụ thể

TF-IDF VECTOR (chỉ show các feature xuất hiện trong câu & có trong vocab)

Feature (Token/N-gram)	Vocab Index	IDF	TF-IDF (x _i)
lũ ngu	32182	9.98277	0.45028
sai chính_tả	43205	9.135473	0.412062
vô_học	47261	9.001941	0.406039
chính_tả	2192	8.442325	0.380797
viết	46897	6.650566	0.299979
lũ	32136	6.371852	0.287407
sai	43204	6.345184	0.286204
ngu	40762	5.567954	0.251147



Phân tích một case cụ thể²

MULTINOMIAL NAIVE BAYES SCORES

Class	Label	prior_log = logP(c)	evidence_log=sum(x_i*logP(w c))	score_log=prior+evidence
2	Hate	-2.235575	-25.072298	-27.307874
1	Offensive	-2.701751	-25.353722	-28.055472
0	Clean	-0.191183	-30.629112	-30.820295

=> PREDICTED: 2 (Hate)




Phân tích một case cụ thể

LOCAL EXPLANATION (top token/ngram giúp pred ra Hate)

Feature (Token)	TF-IDF (xi)	LogP (w Hate)	LogP (w Offensive)	LogP (w Clean)	Contrib Hate	Contrib Offen	Contrib Clean	Δ vs Offen	Δ vs Clean
lũ ngu	0.4503	-9.04	-13.68	-16.06	-4.07	-6.16	-7.23	2.09	3.16
lũ	0.2874	-6.16	-7.82	-9.65	-1.77	-2.25	-2.77	0.48	1
vô_học	0.406	-8.54	-8.83	-16.06	-3.47	-3.59	-6.52	0.12	3.05
ngu	0.2511	-5.48	-5.87	-8.32	-1.38	-1.47	-2.09	0.1	0.71
viết	0.3	-7.99	-7.87	-7.78	-2.4	-2.36	-2.33	-0.04	-0.06
sai	0.2862	-7.61	-7.1	-7.29	-2.18	-2.03	-2.09	-0.15	-0.09
chính_tả	0.3808	-10.14	-9.49	-9.24	-3.86	-3.61	-3.52	-0.25	-0.34
sai chính_tả	0.4121	-14.43	-9.41	-9.88	-5.95	-3.88	-4.07	-2.07	-1.87



DEMO





DEMO

Input & Output

Input text

đồng bào miền trung rất khó khăn, chúng ta phải trợ giúp

Top-K TF-IDF terms

15

Top-K terms per class (P(t|c))

25

Step-by-step (tua chậm)

Tốc độ tua (giây / bước)

1

Nhấn thật (để phân tích đúng/sai) — chọn nếu bạn biết ground-truth

0 — CLEAN

Predict & Explain

Prediction


CLEAN (0)

Explainability — TF-IDF → MultinomialNB (step-by-step)

Overview scores Step-by-step (manual) Learned P(t|c) Token evidence (đúng/sai)

Tổng hợp điểm theo từng lớp

label_id	label_name	log_prior	log_likelihood	log_posterior_unnorm	softmax(log_posterior)
0	CLEAN	-0.1912	-17.8408	-18.032	0.7226
2	HATE	-2.2356	-16.7637	-18.9992	0.2747
1	OFFENSIVE	-2.7018	-20.8969	-23.5986	0.0028



Ý nghĩa các cột

- $\log P(c)$: prior theo lớp
- $\log P(x \mid c)$: likelihood (cộng dồn theo token)
- $\log P(c) + \log P(x \mid c)$: posterior chưa chuẩn hoá
- softmax: để nhìn trực quan “lớp nào trội hơn”



DEMO

Bước 2/5: Preprocessing (ẩn) → TF-IDF biến text thành vector x

Text sau preprocessing: `đồng_bào miền trung khó_khăn , chúng_ta trợ_giúp`

- $n_features = 50000$
- $nnz = 4$
- $sparsity = 0.999920$
- $\|x\|_2 = 1.000000$

Top TF-IDF terms trong input:

term	tfidf
miền trung	0.587
đồng_bào	0.549
miền	0.4426
trung	0.3977

Ground-truth = CLEAN. Mô hình dự đoán ĐÚNG.

C) Phân tích lỗi so với ground-truth (CLEAN) ⇄

$$\text{delta}_t = x_t \cdot (\log P(t \mid \text{pred}) - \log P(t \mid \text{true}))$$

- delta_t dương lớn: token kéo mô hình về lớp dự đoán hơn lớp đúng
- delta_t âm: token ủng hộ lớp đúng nhưng không đủ mạnh

term	tfidf	logP(term pred)	logP(term alt)	delta_pred_minus_alt
đồng_bào	0.549	-10.2653	-10.2653	0
trung	0.3977	-7.1351	-7.1351	0
miền trung	0.587	-9.9967	-9.9967	0
miền	0.4426	-7.9073	-7.9073	0

D) Thống kê phân bố token của input trong tập train

Token	In CLEAN (0)	In OFFENSIVE (1)	In HATE (2)	Total Count	% CLEAN	% OFFENSIVE	% HATE
trung	270	9	70	349	77.4	2.6	20.1
miền	57	2	22	81	70.4	2.5	27.2
đồng_bào	8	1	8	17	47.1	5.9	47.1
miền trung	7	0	2	9	77.8	0	22.2

Cách dùng bảng này để giải thích:

- Nếu một token xuất hiện rất nhiều ở một lớp trong train, nó có thể tạo “lexical bias”.
- Khi mô hình đoán sai, thường thấy token “kéo” về lớp sai vì token đó có phân bố nghiêng trong train.



DEMO

Bước 2/5: Preprocessing (ẩn) → TF-IDF biến text thành vector x

Text sau preprocessing: `đồng_bào miền trung khó_khăn , chúng_ta trợ_giúp`

- $n_features = 50000$
- $nnz = 4$
- $sparsity = 0.999920$
- $\|x\|_2 = 1.000000$

Top TF-IDF terms trong input:

term	tfidf
miền trung	0.587
đồng_bào	0.549
miền	0.4426
trung	0.3977

Ground-truth = CLEAN. Mô hình dự đoán ĐÚNG.

C) Phân tích lỗi so với ground-truth (CLEAN) ⇄

$$\mathit{delta}_t = x_t \cdot (\log P(t \mid \mathit{pred}) - \log P(t \mid \mathit{true}))$$

- delta_t dương lớn: token kéo mô hình về lớp dự đoán hơn lớp đúng
- delta_t âm: token ủng hộ lớp đúng nhưng không đủ mạnh

term	tfidf	logP(term pred)	logP(term alt)	delta_pred_minus_alt
đồng_bào	0.549	-10.2653	-10.2653	0
trung	0.3977	-7.1351	-7.1351	0
miền trung	0.587	-9.9967	-9.9967	0
miền	0.4426	-7.9073	-7.9073	0

D) Thống kê phân bố token của input trong tập train

Token	In CLEAN (0)	In OFFENSIVE (1)	In HATE (2)	Total Count	% CLEAN	% OFFENSIVE	% HATE
trung	270	9	70	349	77.4	2.6	20.1
miền	57	2	22	81	70.4	2.5	27.2
đồng_bào	8	1	8	17	47.1	5.9	47.1
miền trung	7	0	2	9	77.8	0	22.2

Cách dùng bảng này để giải thích:

- Nếu một token xuất hiện rất nhiều ở một lớp trong train, nó có thể tạo “lexical bias”.
- Khi mô hình đoán sai, thường thấy token “kéo” về lớp sai vì token đó có phân bố nghiêng trong train.



DEMO

Input & Output ⇄

Input text

lũ lụt đồng bào miền trung rất khó khăn, chúng ta phải trợ giúp

Top-K TF-IDF terms

15

Top-K terms per class (P(t|c))

25

☒ Step-by-step (tua chậm)

Tốc độ tua (giây / bước)

1

Nhấn thật (để phân tích đúng/sai) — chọn nếu bạn biết ground-truth

0 — CLEAN

Predict & Explain

Prediction


HATE (2)

Explainability — TF-IDF → MultinomialNB (step-by-step)

Overview scores Step-by-step (manual) Learned P(t|c) Token evidence (đúng/sai)

Tổng hợp điểm theo từng lớp

label_id	label_name	log_prior	log_likelihood	log_posterior_unnorm	softmax(log_posterior)
2	HATE	-2.2356	-19.8034	-22.039	0.8523
0	CLEAN	-0.1912	-23.7971	-23.9883	0.1213
1	OFFENSIVE	-2.7018	-22.8138	-25.5156	0.0263



Ý nghĩa các cột

- $\log P(c)$: prior theo lớp
- $\log P(x \mid c)$: likelihood (cộng dồn theo token)
- $\log P(c) + \log P(x \mid c)$: posterior chưa chuẩn hoá
- softmax: để nhìn trực quan “lớp nào trội hơn”



DEMO

Bước 2/5: Preprocessing (ẩn) → TF-IDF biến text thành vector x

Text sau preprocessing: `lũ_lụt đồng_bào miền trung khó_khăn , chúng_ta trợ_giúp`

- $n_features = 50000$
- $nnz = 5$
- $sparsity = 0.999900$
- $\|x\|_2 = 1.000000$

Top TF-IDF terms trong input:

term	tfidf
lũ_lụt	0.5659
miền trung	0.484
đồng_bào	0.4526
miền	0.3649
trung	0.3279

Ground-truth = CLEAN, nhưng mô hình dự đoán = HATE. Đây là lỗi dự đoán.

C) Phân tích lỗi so với ground-truth (CLEAN)

$$\text{delta}_t = x_t \cdot (\log P(t \mid \text{pred}) - \log P(t \mid \text{true}))$$

- delta_t dương lớn: token kéo mô hình về lớp dự đoán hơn lớp đúng
- delta_t âm: token ủng hộ lớp đúng nhưng không đủ mạnh

term	tfidf	logP(term pred)	logP(term alt)	delta_pred_minus_alt
lũ_lụt	0.5659	-10.5711	-16.0591	3.1056
đồng_bào	0.4526	-8.7622	-10.2653	0.6803
miền	0.3649	-7.5154	-7.9073	0.143
trung	0.3279	-6.7467	-7.1351	0.1273
miền trung	0.484	-10.126	-9.9967	-0.0626

D) Thống kê phân bố token của input trong tập train

Token	In CLEAN (0)	In OFFENSIVE (1)	In HATE (2)	Total Count	% CLEAN	% OFFENSIVE	% HATE
trung	270	9	70	349	77.4	2.6	20.1
miền	57	2	22	81	70.4	2.5	27.2
đồng_bào	8	1	8	17	47.1	5.9	47.1
miền trung	7	0	2	9	77.8	0	22.2
lũ_lụt	0	1	1	2	0	50	50

Cách dùng bảng này để giải thích:

- Nếu một token xuất hiện rất nhiều ở một lớp trong train, nó có thể tạo “lexical bias”.
- Khi mô hình đoán sai, thường thấy token “kéo” về lớp sai vì token đó có phân bố nghiêng trong train.



DEMO

Bước 2/5: Preprocessing (ẩn) → TF-IDF biến text thành vector x

Text sau preprocessing: `lũ_lụt đồng_bào miền trung khó_khăn , chúng_ta trợ_giúp`

- $n_features = 50000$
- $nnz = 5$
- $sparsity = 0.999900$
- $\|x\|_2 = 1.000000$

Top TF-IDF terms trong input:

term	tfidf
lũ_lụt	0.5659
miền trung	0.484
đồng_bào	0.4526
miền	0.3649
trung	0.3279

Ground-truth = CLEAN, nhưng mô hình dự đoán = HATE. Đây là lỗi dự đoán.

C) Phân tích lỗi so với ground-truth (CLEAN)

$$\Delta_t = x_t \cdot (\log P(t \mid pred) - \log P(t \mid true))$$

- Δ_t dương lớn: token kéo mô hình về lớp dự đoán hơn lớp đúng
- Δ_t âm: token ủng hộ lớp đúng nhưng không đủ mạnh


term	tfidf	logP(term pred)	logP(term alt)	delta_pred_minus_alt
lũ_lụt	0.5659	-10.5711	-16.0591	3.1056
đồng_bào	0.4526	-8.7622	-10.2653	0.6803
miền	0.3649	-7.5154	-7.9073	0.143
trung	0.3279	-6.7467	-7.1351	0.1273
miền trung	0.484	-10.126	-9.9967	-0.0626

D) Thống kê phân bố token của input trong tập train

Token	In CLEAN (0)	In OFFENSIVE (1)	In HATE (2)	Total Count	% CLEAN	% OFFENSIVE	% HATE
trung	270	9	70	349	77.4	2.6	20.1
miền	57	2	22	81	70.4	2.5	27.2
đồng_bào	8	1	8	17	47.1	5.9	47.1
miền trung	7	0	2	9	77.8	0	22.2
lũ_lụt	0	1	1	2	0	50	50

Cách dùng bảng này để giải thích:

- Nếu một token xuất hiện rất nhiều ở một lớp trong train, nó có thể tạo “lexical bias”.
- Khi mô hình đoán sai, thường thấy token “kéo” về lớp sai vì token đó có phân bố nghiêng trong train.



**THANK
YOU!**



Group: PhuongThanhThuc